EMSI Casablanca

Rapport de Projet MLOps

Entraînement et comparaison de modèles prédictifs : Détection de pannes

Malak AZALIM

Groupe : 5iada g2

1. Introduction et Contexte

Ce projet s'inscrit dans une démarche MLOps visant à déployer une chaîne de traitement complète et reproductible. L'objectif industriel est de détecter de manière anticipée les pannes d'un équipement à partir de relevés de capteurs. Le travail livré comprend le chargement sécurisé des données, un découpage rigoureux, l'entraînement comparatif de plusieurs modèles, et la sérialisation du modèle retenu.

2. Les Données

Le jeu de données (`exemple_pannes.csv`) est fortement déséquilibré, ce qui oriente le choix des métriques d'évaluation.

Caractéristique	Détail
Volume	5 000 observations, 4 variables numériques.
Cible	`failure` (0 = fonctionnement normal, 1 = panne).
Déséquilibre	17,6 % de pannes (878 lignes) pour 82,4 % de non-pannes.
Nettoyage	Suppression des lignes sans cible via `dropna()`.

3. Implémentation Logicielle

Le code a été structuré pour être réutilisable. Le découpage en modules sépare la préparation des données, la définition des modèles et la logique d'entraînement.

> **Modifications apportées :**
> • `data.py` : Implémentation du découpage (aléatoire ou chronologique) avec conservation des proportions via stratification (`stratify=y`).
> • `models.py` : Ajout d'une *Baseline* obligatoire (DummyClassifier prédisant la classe majoritaire) et de 4 algorithmes candidats.
> • `train.py` : Création d'un pipeline complet évaluant l'accuracy, le recall, la precision et le score F1.

4. Validation par les Tests

La fiabilité du pipeline est garantie par l'exécution de tests unitaires (TDD). Le projet valide les 8 tests exigés, prouvant que le code respecte les contraintes techniques.

> **État des tests (pytest) : 8 / 8 réussis.**
> Les tests vérifient notamment que l'entraînement est bien isolé du test, que la baseline est toujours évaluée en premier, et que le modèle final enregistré bat strictement cette baseline sur la métrique métier choisie.

5. Résultats et Choix du Modèle

Les modèles ont été évalués sur un jeu de test de 1 000 observations n'ayant pas servi à l'apprentissage.

Modèle	Accuracy	Recall	Precision
Gradient Boosting (Retenu)	**0.888**	**0.608**	**0.713**
Régression logistique	0.889	0.574	0.737
Random Forest	0.881	0.557	0.705
Baseline (DummyClassifier)	0.824	0.000	0.000

6. Justification Métier

Le choix du Recall : En maintenance industrielle, manquer une panne (faux négatif) entraîne l'arrêt de la production et coûte beaucoup plus cher qu'une fausse alerte (faux positif). C'est pourquoi le *Recall* a été désigné comme métrique principale.

Le choix du modèle : L'accuracy est trompeuse ici : la Baseline atteint 82,4% d'accuracy mais ne détecte absolument aucune panne (Recall = 0). Le **Gradient Boosting** a été retenu car il offre le meilleur Recall (0.608), détectant plus de 60% des pannes réelles, tout en conservant un score F1 très solide (0.656).

> **Limites et Améliorations :**
> La principale limite actuelle est le déséquilibre des classes. Pour améliorer le Recall à l'avenir, il faudra appliquer des poids aux classes (`class_weight`) ou utiliser des techniques de suréchantillonnage comme SMOTE.